

Premature Lexical Correction in Multimodal LLMs via Deferred Context Grounding

Marcos Almeida

`marcos18motorola@gmail.com`

July 2026

Resumo

Este trabalho documenta uma falha sistêmica em modelos de linguagem multimodais de última geração: a correção lexical prematura. Quando expostos a sequências textuais de baixa probabilidade estatística, mas gramaticalmente válidas, os modelos aplicam uma autocorreção agressiva baseada em vieses puramente textuais antes de realizar o alinhamento cruzado (*cross-modal grounding*) com imagens enviadas em turnos subsequentes. Apresentamos um estudo de caso controlado utilizando a frase “O gato subscreveu na telha”, replicado empiricamente em quatro LLMs de produção.

1 Introdução

Os modelos de linguagem multimodais proeminentes tratam tokens de texto e imagem sob uma arquitetura unificada de atenção. Contudo, há um gargalo operacional na inferência quando o envio ou processamento do input textual precede o token visual. Este artigo isola o fenômeno da correção lexical prematura, onde o viés probabilístico do texto anula termos legítimos antes que o contexto visual possa validá-los.

2 Metodologia

O experimento foi desenhado utilizando uma construção sintática em língua portuguesa propositalmente próxima a um clichê linguístico massivamente presente nas bases de treinamento (“O gato subiu no telhado”), mas modificando o verbo para um termo raro e formal, porém totalmente válido:

- **Input Textual (Turno 1):** “O gato subscreveu na telha”
- **Input Visual (Turno 2):** Imagem do personagem *Gato Félix* escrevendo/assinando fisicamente um bilhete sobre uma superfície de telhas.

O teste cego foi aplicado de forma idêntica em quatro ambientes isolados (abas limpas, sem histórico) nas seguintes plataformas em julho de 2026: Claude 3.5 Sonnet (Anthropic), Meta AI (Meta), Gemini (Google) e ChatGPT (OpenAI).

Um estudo de caso estendido e detalhado de 8 turnos foi conduzido com o modelo Claude 3.5 Sonnet para realizar a engenharia reversa do comportamento limitante da arquitetura.

3 Resultados Experimentais

Todos os quatro modelos avaliados exibiram o comportamento de correção precoce no Turno 1, gerando falsos positivos ao classificar a frase legítima do usuário como um erro de digitação ou falha de corretor automático. A Tabela 1 sintetiza as respostas iniciais observadas:

Tabela 1: Respostas dos modelos ao turno puramente textual.

Modelo	Correção Presumida	Padrão da Resposta Inicial
Claude 3.5 Sonnet	subscreveu → subiu	“Acho que quiseste dizer ‘subiu’...”
Meta AI	subscreveu → subiu	“Acho que esse gato aí quis assinar a Netflix...”
Gemini	subscreveu → subiu	“O termo correto provavelmente seria...”
ChatGPT	subscreveu → subiu	“A frase não faz sentido... O mais natural é...”

Após o envio do componente visual no Turno 2, o modelo Claude 3.5 Sonnet realizou o *grounding* correto, recuou em sua assunção e admitiu textualmente: *“Eu funciono prevendo a próxima palavra/token mais provável com base no contexto. Então, no fundo, meu ‘erro de interpretação’ foi uma previsão... baseada em contexto incompleto”*.

Os logs visuais e prints completos indexados cronologicamente estão disponíveis no repositório de evidências em: <https://github.com/servodecristorj-ai/premature-lexical-correction-multimodal-llms>.

4 Relatório Técnico de Engenharia Reversa (Claude)

Abaixo, transcreve-se o parecer técnico e as diretrizes arquiteturais formalizadas pelo próprio modelo sob a perspectiva de engenharia de sistemas após o encerramento do teste:

Causa técnica: O modelo opera por decodificação autoregressiva, estimando a distribuição de probabilidade do próximo token condicionada ao contexto disponível ($P(\text{token}_i \mid \text{token}_1 \dots \text{token}_{i-1}, \text{contexto dois})$). Na ausência da imagem, o contexto textual isolado tornou “subscreveu” um outlier de baixa probabilidade dentro da distribuição esperada para a construção sintática “gato + verbo + telha”, em

comparação com candidatos de alta frequência como “subiu”. Isso ativou um comportamento de correção ortográfica/lexical baseado unicamente em plausibilidade estatística do texto, sem mecanismo de verificação cruzada (*cross-modal grounding*) com sinais visuais que só chegaram em turno posterior.

5 Mitigações Propostas

Com base no diagnóstico, propõem-se três modificações estruturais nas pipelines multimodais:

1. **Verificação de Incerteza (Uncertainty-Aware Correction):** Definir um limiar onde, caso o token observado exista no vocabulário legítimo da língua, o modelo levante uma hipótese consultiva ao invés de aplicar uma correção impositiva.
2. **Retenção de Julgamento (Deferred Judgment):** Postergar decisões de normalização lexical em contextos de chat ativos até que o grafo multimodal seja totalmente mapeado.
3. **Calibração Lexical:** Atenuar a penalidade probabilística aplicada a termos formais ou raros quando integrados a estruturas sintáticas coerentes.

6 Conclusão

Este estudo demonstrou com sucesso que as LLMs de produção atuais priorizam vieses estatísticos de texto puro (*text-only priors*) em detrimento de uma postura de espera multimodal ativa. A correção precoce prejudica a usabilidade em termos técnicos ou raros, demandando ajustes finos na camada de decodificação autoregressiva.